

Progetto d'esame di Probabilità e Statistica

Sommario

Descrizione delle variabili:	2
Analisi dataset.....	3
Anno di costruzione:	4
Variabili numeriche	5
Valore totale dei lotti	5
Valore singoli edifici	7
Valore singoli terreni	9
Area terreni	10
Area piano terra	12
Relazioni	14
Test indipendenza.....	20
Intervallo di confidenza per la media di SqFt e di Total.....	22
Test d'ipotesi tra due popolazioni	24
Regressione multipla	26

Descrizione delle variabili:


Il dataset utilizzato contiene i dati provenienti da 100 proprietà immobiliari (ognuna identificata da un numero ID) scelte randomicamente dal sito web pubblico della contea di Wake nello stato della North Carolina. Ogni immobile è caratterizzato dall'avere 11 variabili. Queste variabili includono: ID, anno di costruzione, area del piano terra, costo dell'immobile, costo del terreno, costo complessivo, numero di bagni, ecc... Le uniche variabili qualitative sono il codice di avviamento postale (ZIP) e il numero identificativo ID. Sotto una tabella di riepilogo delle variabili presenti nel database:

NOME	DESCRIZIONE	TIPO
ID	Il numero identificativo dato dalla contea all'edificio	Qualitativa
YEARBUILT	Anno di costruzione della struttura	Quantitativa discreta
SQFT	Area del piano terra in piedi quadri (in [ft ²])	Quantitativa
STORY	Quanti piani ha la struttura (in piani)	Quantitativa discreta
ACRES	Quanti acri contiene il lotto (in acri, 1 acre= 4096.5 m ²)	Quantitativa
NOBATHS	Numero di bagni nella residenza	Quantitativa discreta
FIREPLACES	Numero di camini nella residenza	Quantitativa discreta
TOTAL	Il valore totale della proprietà in dollari	Quantitativa
LAND	Il valore del terreno in dollari	Quantitativa
BUILDING	Valore dell'edificio in dollari	Quantitativa
ZIP	Codice postale	Qualitativa

Analisi dataset


Prendendo in considerazione la variabile STORY che contiene il numero di piani della struttura notiamo che si tratta di una variabile quantitativa discreta: il fatto che alcuni valori siano in decimali è legato al fatto che probabilmente è stata fatta una media del numero di piani nello specifico edificio, quindi ci saranno porzioni di edificio che contengono due piani e altri che contengono un solo piano ad esempio.

```
load woodard.mat
%Utilizziamo la funzione Unique per vedere se abbiamo un numero adeguato di
%variabili da poter essere letto in un grafico a torta
unique(Story);
pie(categorical(Story))
title("Numero di piani nell'edificio")
```




Possiamo notare dal grafico a torta, come la maggior parte degli edifici ovvero il 57% risulti avere un solo piano. Discorso analogo possiamo farlo con le variabili **NoBaths** e **Fireplaces** rispettivamente il numero di bagni e il numero di camini all'interno dell'edificio:

```
pie(categorical(NoBaths))
title("Numero di bagni nell'edificio")
```




```
pie(categorical(Fireplaces))
title("Numero di camini nell'edificio")
```



Notiamo dai dati fornitoci che la maggior parte degli edifici analizzati possiede un camino e due bagni.

Anno di costruzione:

```
histogram(YearBuilt)
xlabel('Anno di costruzione')
ylabel('Numero lotti')
title('Istogramma anno di costruzione')
```



Variabili numeriche

Valore totale dei lotti

Per quanto riguarda le variabili numeriche consideriamo il prezzo totale dei lotti:

```
x=min(Total);
disp(['Il minimo è: ', int2str(x)])
```

Il minimo è: 32184

```
x=max(Total);
disp(['Il massimo è: ', int2str(x)])
```

Il massimo è: 4904102


```
x=mean(Total);
disp(['La media è: ', int2str(x)])
```

La media è: 258574

```
x=std(Total);
disp(['La deviazione standard è: ', int2str(x)])
```


La deviazione standard è: 491069

```
histogram(Total)
xlabel('Prezzo lotto(in $)')
ylabel('Numero lotti')
title('Istogramma prezzo totale lotto(in $)')
```



Notiamo che la distribuzione è asimmetrica ed è spostata tutta verso sinistra, quindi non possiamo considerare l'andamento della distribuzione Gaussiano. Inoltre notiamo dei valori outliers a 1 milione di dollari e a poco meno di 5 milioni. Mentre se analizziamo il boxplot, notiamo che il 50% dei lotti ha un prezzo compreso tra 123548\$ e 281072\$ mentre possiamo notare 3 lotti outlier con il più costoso che vale 4904102\$

```
boxplot(Total, 'Widths', 1.5)%
ylabel('Prezzo lotti (in $)')
title('Boxplot prezzo totale lotti', 'FontSize', 8)
```



Valore singoli edifici

Ora valutiamo l'andamento del prezzo dei singoli edifici, quindi il valore totale meno il valore del terreno. Se prendiamo in considerazione il boxplot notiamo come il 50% delle case ha un valore compreso tra 85335\$ e 155853\$ con 5 edifici il cui prezzo è outlier con il più costoso che vale 634230\$.

```
x=min(Building);
disp(['Il minimo è:', int2str(x)])
```

Il minimo è:6490

```
x=max(Building);
disp(['Il massimo è: ', int2str(x)])
```

Il massimo è: 634230

```
x=mean(Building);
disp(['La media è: ', int2str(x)])
```


La media è: 132894

```
x=std(Building);
disp(['La deviazione standard è: ', int2str(x)])
```


La deviazione standard è: 85157

```
histogram(Building)
xlabel('Prezzo edificio (in $)')
```

```
ylabel('Numero edifici')
title('Istogramma prezzo degli edifici')
```



```
boxplot(Building, 'Widths', 1.5)%
ylabel('Prezzo edifici (in $)')
title('Boxplot prezzo degli edifici')
```



Valore singoli terreni

Ora valutiamo i valori dei singoli terreni:

```
x=min(Land);  
disp(['Il minimo è: ', int2str(x)])
```

Il minimo è: 0

```
x=max(Land);  
disp(['Il massimo è: ', int2str(x)])
```

Il massimo è: 4797750


```
x=mean(Land);  
disp(['La media è: ', int2str(x)])
```

La media è: 125700


```
x=std(Land);  
disp(['La deviazione standard è: ', int2str(x)])
```

La deviazione standard è: 477298

```
histogram(Land)  
xlabel('Prezzo terreno (in $)')  
ylabel('Numero terreni')  
title('Istogramma prezzo dei terreni')
```



```
boxplot(Land, 'Widths', 1.5, "DataLim", [0, 1e6], "ExtremeMode", "compress")
ylabel('Prezzo terreni (in $)')
title('Boxplot prezzo dei terreni')
```



Area terreni

Ora valutiamo l'area dei singoli terreni e notiamo dal diagramma che i dati non sono distribuiti come una normale. Il 50% è compreso tra 0.2 acri e 0.505 acri mentre abbiamo un outlier per il lotto numero 5 che ha un'area di 37.98 acri

```
x=min(Acres);  
disp(['Il minimo è: ', int2str(x)])
```

Il minimo è: 0

```
x=max(Acres);  
disp(['Il massimo è:', int2str(x)])
```

Il massimo è:39


```
x=mean(Acres);  
disp(['La media è: ', int2str(x)])
```

La media è: 1

```
x=std(Acres);  
disp(['La deviazione standard è: ', int2str(x)])
```

La deviazione standard è: 4


```
histogram(Acres)  
xlabel('Area terreno (in acre)')  
ylabel('Numero terreni')  
title('Istogramma area dei terreni')
```



```

boxplot(Acres, 'Widths', 1.5, "DataLim", [0, 1], "ExtremeMode", "compress")
ylabel('Area terreni (in acre)')
title("Boxplot dell'area terreni")

```



Area piano terra

Notiamo che l'andamento è tutto portato a sinistra e il 50% è contenuto tra 0.2 ft² e 0.505 ft² e l'outlier più grande dal valore di 4650 ft²

```

x=min(SqFt);
disp(['Il minimo è: ', int2str(x)])

```

Il minimo è: 705

```

x=max(SqFt);
disp(['Il massimo è:', int2str(x)])

```

Il massimo è: 4650

```

x=mean(SqFt);
disp(['La media è: ', int2str(x)])

```

La media è: 1730


```

x=std(SqFt);
disp(['La deviazione standard è: ', int2str(x)])


```

La deviazione standard è: 719

```
histogram(SqFt)
xlabel('Area piano terra (in ft^2)')
ylabel('Numero edifici')
title('Istogramma piani terra')
```




```
boxplot(SqFt, 'Widths',1.5)
ylabel('Area piano terra (in ft^2)')
title("Boxplot area dei piani terra")
```




Relazioni

Cerchiamo ora le relazioni tra le variabili e notiamo che potrebbe esserci una relazione di tipo lineare nei grafici n. 2, 4, 5 quindi ha senso fare dell'inferenza su questi grafici.

```
%P anno di costruzione - valore totale lotto
plot(YearBuilt,Total,'*')
xlabel('Anno di costruzione')
ylabel('Valore totale lotto')
title('(1) anno di costruzione - valore totale lotto(in $)')
```




```
%P area piano terra - valore totale lotto
plot(SqFt,Total,'*')
xlabel('Area piano terra in ft^2')
ylabel('Valore totale lotto')
title('(2) area piano terra in ft^2 - valore totale lotto(in $)')
```



```

%P area terreno in acre - valore totale lotto
plot(Acres,Total, '*')
% xlim([0 5])
% ylim([0 1e5])
xlabel('area terreno in acre')
ylabel('Valore totale lotto(in $)')
title('(3) area terreno in acre - valore totale lotto(in $)')


```




```

%P valore terreno - valore totale lotto
plot(Land,Total, '*')
xlabel('Valore terreno (in $)')
ylabel('Valore totale lotto(in $)')
title('(4) Valore terreno (in $) - valore totale lotto(in $)')

```





```
%Pvalore edificio - valore totale lotto
plot(Building,Total,'*')
xlabel('Valore edificio (in $)')
ylabel('Valore totale lotto(in $)')
title('(5) Valore edificio (in $) - valore totale lotto(in $)')
```





Proviamo a valutare una possibile sottopopolazione in base all'anno di costruzione per quanto riguarda il costo dell'edificio, ma non sembrano esserci sottopopolazioni che soddisfano questi requisiti:

```
plot(YearBuilt,Building, '*')
xlabel('Anno di costruzione')
ylabel('Valore edificio (in $)')
title('(6) Anno di costruzione - valore edificio (in $)')
```



```
%y1=find((1980 <= YearBuilt) & (YearBuilt <= 1990))
y1=find( YearBuilt <= 1970 );
%y2=find(YearBuilt<1980)
y2=find(1970 <=YearBuilt);
%y3=find(YearBuilt>1990)
X=Total;
plot(y1,X(y1), '*b',y2,X(y2), '+k') %,y3,X(y3), 'or'
```



Test indipendenza

Il test di indipendenza viene condotto per valutare dalle osservazioni e dalle frequenze osservate di due variabili, se queste hanno una qualche forma di legame tra di loro, oppure se questi dati risultano indipendenti l'uno dall'altro. Il test parte con la suddivisione in classi delle due variabili, tale che ogni classe abbia al proprio interno almeno 5 osservazioni, se esistono classi con pochi elementi queste vengono accorpate così da formare una classe da almeno 5 elementi e ogni classe deve essere mutuamente esclusiva. L'ipotesi nulla che si fa è le due caratteristiche siano indipendenti tra di loro ovvero che la probabilità congiunta è uguale al prodotto delle probabilità marginali: $H_0 : P_{(i,j)} = P_{\bullet,j} \cdot P_{i,\bullet}$. Fatto ciò si procede alla costruzione della tabella delle delle frequenze attese e si procede ad utilizzare la statistica:

$$\chi^2(k-1)(l-1) \sim \sum_{i=1}^k \sum_{j=1}^l \frac{(N_{i,j} - n\hat{P}_{\bullet,j} \cdot \hat{P}_{i,\bullet})^2}{n\hat{P}_{\bullet,j} \cdot \hat{P}_{i,\bullet}} \text{ dove } \hat{P}_{\bullet,j} = \frac{N_{\bullet,j}}{n} \text{ e } \hat{P}_{i,\bullet} = \frac{N_{i,\bullet}}{n}$$

```
%TEST INDIPENDENZA tra la variabile NoBaths (2 classi) e Fireplaces (2 classi)
```

```
%Tabella requeenze osservate
```

```
foss=zeros(2,2);
```

```
%Tabella requeenze attese
```

```
fatt=zeros(2,2);
```

```
%Creo l'array delle frequenze osservate
```

```
foss(1,1)=size(find((NoBaths<=2) & (Fireplaces==0)),1);
```

```
foss(1,2)=size(find((NoBaths<=2) & (Fireplaces ~= 0)),1);
```

```
foss(2,1)=size(find((NoBaths>2) & (Fireplaces == 0)),1);
```

```
foss(2,2)=size(find((NoBaths>2) & (Fireplaces ~= 0)),1);
```

```
%Associo l'array ad una tabella così da mostrarla a schermo
```

```
t_foss=array2table(foss,"VariableNames',{'Numero camini = 0','Numero camini /= 0'},
```

```
'RowNames',{'Numero bagni <= 2','Numero bagni > 2'});
```

```
disp(['La tabellla della frequenze osservate è'])
```

La tabellla della frequenze osservate è

```
disp(t_foss)
```

	Numero camini = 0	Numero camini /= 0
Numero bagni <= 2	24	40
Numero bagni > 2	4	31

Per fare ciò, valutiamo prima le frequenze marginali $N_{\bullet,j}$ e $N_{i,\bullet}$ e costruisco la mia tabella di

frequenze attese $n\hat{P}_{\bullet,j} \cdot \hat{P}_{i,\bullet} = \frac{N_{\bullet,j} \cdot N_{i,\bullet}}{n}$

```

%Frequenze marginali
N_j=sum(foss,1);
Ni_=(sum(foss,2));

%Numero totale elementi
n=sum(N_j)+sum(Ni_);

%Calcolo la statistica chi quadro
chi_2=0;
for j=1:2
    for i=1:2
        %Creo la tabella delle frequenze attese
        fatt(j,i)=N_j(1,i)*Ni_(j,1)/n;
        %Calcolo la mia statistica
        chi_2 = chi_2 + (foss(j,i)-fatt(j,i))^2/fatt(j,i);
    end
end
t_fatt=array2table(fatt,"VariableNames",{ 'Numero camini = 0', 'Numero camini /=
0'}, "RowNames",{ 'Numero bagni <= 2', 'Numero bagni > 2'});
disp(['La tabellla della frequenze attese è'])
disp(t_fatt)

```

	Numero camini = 0	Numero camini /= 0
Numero bagni <= 2	9.0505	22.949
Numero bagni > 2	4.9495	12.551

chi_2

chi_2 = 64.6644

chi2inv(0.95,1)

ans = 3.8415

```

%Confronto con la chi quadro al 5% di sifgnicatività e 1 grado di libertà

if (chi_2>chi2inv(0.95,1))
    disp(['Ipotesi nulla rifiutata, dai dati risulta che le variabili non sono
indipendenti'])
else
    disp(['Ipotesi nulla va accettata, dai dati risulta che le variabili sono
indipendenti'])
end

```

Ipotesi nulla rifiutata, dai dati risulta che le variabili non sono indipendenti

Intervallo di confidenza per la media di SqFt e di Total

Per l'intervallo di confidenza della media prendiamo in considerazione la variabile **SqFt** ovvero l'area del piano terra dell'edificio e la variabile **Total** ovvero la variabile che descrive il prezzo totale dell'immobile. Scegliamo un livello di significatività al 5% e consideriamo la σ incognita. Prendiamo un campione di 30 dati dalla mia popolazione (che in questo caso è rappresentato dalla banca dati che stiamo analizzando). Da questo campione calcoliamo media e scarto campionario e calcoliamo la t-student, la statistica test che dobbiamo utilizzare. In alternativa avremmo potuto ipotizzare varianza vera, ovvero la varianza campionaria applicata a tutta la popolazione e, come statistica test, la normale. Utilizziamo l'ipotesi di varianza incognita per metterci nella peggiore delle ipotesi, ovvero la condizione che capita più comunemente nella realtà. Quindi l'intervallo di confidenza sarà di questo tipo:

$$\bar{X} - t_{\alpha/2, n-1} \frac{S}{\sqrt{n}} < \mu < \bar{X} + t_{\alpha/2, n-1} \frac{S}{\sqrt{n}}$$

Valutiamo ora l'intervallo di confidenza per la variabile **SqFt**:

```
%genero 20 numeri casuali
x2=randperm(100,20);
sample=SqFt(x2);

%Media campionaria
m1sample=mean(sample,'omitnan');

%Scarto campionario
s1sample=std(sample,'omitnan');

%Intervallo di confidenza
lim_inf1= m1sample + tinv(0.025,19)*s1sample/sqrt(20);
lim_sup1=m1sample - tinv(0.025,19)*s1sample/sqrt(20);

disp(["l'intervallo di confidenza per la media della variabile SqFt è compreso tra"])
```

l'intervallo di confidenza per la media della variabile SqFt è compreso tra

```
disp([num2str([lim_inf1,lim_sup1]))])
```

1358.561 2127.039

Ora valutiamo l'intervallo di confidenza per la media della variabile **Total**

```
%genero 20 numeri casuali
x2=randperm(100,20);
sample1=Total(x2);
```

```

%Media campionaria
m1sample1=mean(sample1,'omitnan');

%Scarto campionario
s1sample1=std(sample1,'omitnan');

%Intervallo di confidenza
lim_inf2= m1sample1 + tinv(0.025,19)*s1sample1/sqrt(20);
lim_sup2=m1sample1 - tinv(0.025,19)*s1sample1/sqrt(20);

disp(["l'intervallo di confidenza per la media della variabile SqFt è compreso
tra"])

```

l'intervallo di confidenza per la media della variabile SqFt è compreso tra

```
disp([num2str([lim_inf2,lim_sup2])])
```

138038.3173 246927.7827

Test d'ipotesi tra due popolazioni

Per il test d'ipotesi si sono scelte due popolazioni ognuna caratterizzata da una specifica condizione sul proprio **Zip** code:

1. la **prima** popolazione è caratterizzata dall'avere un codice **Zip** inferiore a 27606
2. la **seconda** popolazione è caratterizzata dall'avere un codice **Zip** superiore a 27606

A queste due popolazioni sono stati associati i rispettivi valori della variabile **Acres** e dai valori delle due popolazioni si sono estrapolati due campioni di taglia 30 su cui sono stati calcolati media e varianza campionaria. Si introduce la variabile $d = \mu_1 - \mu_2$ differenza delle medie delle due popolazioni. Si valuta un test d'ipotesi sulla media delle due popolazioni, in particolare l'ipotesi nulla: $H_0 : d = 0$ ovvero che le due popolazioni abbiano la stessa media, quindi si tratta di un test a due code. Si suppone che la media e la varianza della variabile d siano incognite, quindi si utilizza

questo stimatore per la varianza: $S_t = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$ mentre la nostra statistica test è:

$$T(n_1 + n_2 - 2) \sim \frac{\bar{X}_1 + \bar{X}_2 - d}{\sqrt{S_t^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \text{ da confrontare con la t-student } n_1 + n_2 - 2 \text{ gradi di libertà e livello}$$

di significatività al 95%.

```
%individuo le popolazioni dividendo gli Zip Code a metà
%Prima popolazione
p1=find( str2double(string(Zip)) <= 27606 );
%Seconda popolazione
p2=find( 27606 < str2double(string(Zip)));
pop1=Acres(p1);
pop2=Acres(p2);

%Estraggo indici casuali per generare campione della popolazione 1 e 2
s1=randperm(length(pop1),30);
s2=randperm(length(pop2),30);
length(s1);
length(s2);
%Genero campione per la popolazione 1 e 2
samp1=pop1(s1);
samp2=pop2(s2);
length(samp1);
length(samp2);
%Media campionaria popolazione 1, popolazione 2
media1=mean(samp1);
media2=mean(samp2);
```



```
%Varianza campionaria popolazione 1, popolazione 2
var1=var(samp1);
var2=var(samp2);
%Stimo la varianza
Var_st=(var1*(length(samp1)-1)+var2*(length(samp2)-1))/(length(samp1)+length(samp2)-2)
```

```
Var_st = 25.4133
```

```
%Statistica test T valutata per d=0
T=(media1+media2-0)/sqrt(Var_st*(1/length(samp1) + 1/length(samp2)))
```

```
T = 1.6111
```

```
%Confronto il risultato della mia statistica test a due code con la t di student
%con livello di confidenza al 95%
Tst=abs(tinv(0.025,length(samp1)+length(samp2)-2))
```

```
Tst = 2.0017
```

```
if (T>Tst)
disp(['Ipotesi nulla rifiutata, dai dati risulta che la media delle popolazioni è diversa'])
else
    disp(['Ipotesi nulla va accettata, dai dati risulta che le variabili sono indipendenti'])
end
```

```
Ipotesi nulla va accettata, dai dati risulta che le variabili sono indipendenti
```

Regressione multipla

Con la regressione multipla si vuole stabilire se esiste una relazione tra le variabili $X_i = (X_1, X_2, \dots, X_p)$ (**variabili dipendenti**) e Y (**variabile indipendente**). Quindi il nostro scopo è quello di trovare i coefficienti $\beta_1, \beta_2, \dots, \beta_p$ da moltiplicare alle nostre variabili dipendenti dell'iperpiano, ovvero una superficie nello spazio a p dimensioni, tale da minimizzare la distanza tra i punti Y_i e l'iperpiano.

$$y_i = x_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \dots + \beta_p x_{i,p} \quad i = 1, \dots, n$$

dove n è il numero di osservazioni della p -esima variabile.

Come indice della bontà del modello si utilizza l'indice di determinazione multipla $R^2 = \frac{SSR}{SST}$

che rappresenta quanta parte del mio errore è spiegata da X_i e quanta no. Visto che stiamo parlando di regressione multipla abbiamo un altro coefficiente di determinazione "aggiustato" ovvero l' R_a^2 in quanto il valore di SSR cambia anche se si aggiungono nuove variabili (a prescindere del fatto che queste variabili contribuiscano o meno all'accuratezza del modello) per questo quando utilizziamo la funzione **fitlm** integrata in Matlab, in output ci fornirà, oltre le stime dei coefficienti $b_1, b_2, \dots, b_n$ che stiamo cercando, anche il valore del R_a^2

```
tb1=table(Acres,SqFt,NoBaths,YearBuilt,Fireplaces>Total,'VariableNames',{'Acres',  
'Floor Area','No. Baths','Year Built','No.Fireplaces','Total'});  
lm = fitlm(tb1)
```

```
lm =  
Linear regression model:  
Total ~ 1 + Acres + Floor Area + No. Baths + Year Built + No.Fireplaces
```

Estimated Coefficients:

	Estimate	SE	tStat	pValue
(Intercept)	3.4982e+06	1.2186e+06	2.8706	0.0050723
Acres	1.2234e+05	2360	51.839	2.0337e-70
Floor Area	154	15.991	9.6305	1.2376e-15
No. Baths	20977	21897	0.95801	0.34054
Year Built	-1845.9	625.27	-2.9522	0.0039937
No.Fireplaces	4105.1	23080	0.17786	0.85922

```
Number of observations: 99, Error degrees of freedom: 93  
Root Mean Squared Error: 8.89e+04  
R-squared: 0.969, Adjusted R-Squared: 0.968  
F-statistic vs. constant model: 585, p-value = 1.26e-68
```

Notiamo che il valore ottenuto di $R^2 = 0.969$ è vicino all'unità. Quindi il modello di regressione multipla avente come variabili indipendenti quelle elencate nella tabella, è adatto a descrivere il

prezzo totale del lotto. Se analizziamo i valori di p-value ci accorgiamo che le variabili **No. baths** e **No. Fireplaces** hanno valori di p-value piuttosto elevati, quindi è lecito pensare che queste variabili influiscano poco ai fini della bontà del modello. Infatti sia il **p-value** che la statistica **tStat** che la funzione **fitlm** di Matlab ci fornisce per ciascuna variabile, sono quelli ottenuti applicando un test d'ipotesi su ciascun coefficiente. L'ipotesi nulla è $H_0 : \beta_i = 0$, ovvero che non sussista relazione di linearità tra la variabile in esame e la variabile dipendente Y_i , quindi si valuta la statistica test e confrontandola con la t-student a n-2 gradi di libertà:

$$T(n-2) \sim \frac{b_1 - \beta_1}{s_{b_1}}$$

vengono calcolati i p-value in tabella i quali se molto piccoli, dicono che il valore della statistica cade nella regione di rifiuto dell'ipotesi nulla, quindi affermare che la variabile in esame, a partire dai dati ottenuti del campione, ha una relazione lineare con la Y . Questo Matlab lo fa in automatico attraverso la funzione **fitlm**.

Quindi proviamo a rifare la regressione senza queste due variabili e vediamo come cambia l'indice R^2

```
tb2=table(Acres,SqFt,YearBuilt>Total,'VariableNames',{ 'Acres','Floor
Area','Year Built','Total'});
lm1 = fitlm(tb2)
```


```
lm1 =
Linear regression model:
Total ~ 1 + Acres + Floor Area + Year Built
```

Estimated Coefficients:

	Estimate	SE	tStat	pValue
(Intercept)	3.1313e+06	1.1295e+06	2.7722	0.006688
Acres	1.2216e+05	2320.5	52.645	1.2767e-72
Floor Area	163.4	13.027	12.543	6.058e-22
Year Built	-1645.8	575.26	-2.861	0.0051835

```
Number of observations: 100, Error degrees of freedom: 96
Root Mean Squared Error: 8.86e+04
R-squared: 0.968, Adjusted R-Squared: 0.967
F-statistic vs. constant model: 982, p-value = 6.97e-72
```

```
plotResiduals(lm1)
```



Come ci aspettavamo, notiamo che l'indice è rimasto uguale. Quindi le variabili **Acres**, **Floor Area**, **Year Built** bastano a descrivere il modello in modo soddisfacente. Inoltre notiamo che i residui ricordano nei limiti della grandezza del nostro campione, una normale come ci saremmo aspettati dalla proprietà di correttezza dello stimatore dei minimi quadrati (Condizioni di Gauss-Markov). Infine si è elaborata una matrice di Scatter Plot delle variabili utilizzate nel modello di regressione multipla.

```
X=0;
X=[Total Acres SqFt YearBuilt];
xnames = {'Total', 'Acres', 'SqFt', 'YearBuilt'};
[h,ax] = gplotmatrix(X,[],[],[],[],[],[],[], 'variable', xnames);
title('Scatter Plot')
```

Scatter Plot

